

Agricultura Predictiva

Predicción del rendimiento de cultivos colombianos a partir de datos agronómicos mediante Machine Learning

Sofía Vásquez Jaramillo
Sandra Paola Restrepo



Tabla de Contenido

#	SECCIÓN	DIAPOSITIVA
1	Portada	1
2	Objetivo General	3
3	Planteamiento del Problema	4
4	Procesamiento de Datos	5
5	Manejo de Atípicos	6
6	Boxplots – Distribución de Nutrientes	7
7	Separación Categórica por Rendimiento	8–9
8	Serie de Tiempo – Nitrógeno 2018–2024	10–11
9	PCA – Selección de Características	12–13
10	Modelos Supervisados ML	14
11	Matrices de Confusión	15
12	Optimización, Ensamble e Importancia de Variables	16–17
13	Métodos No Supervisados – Clustering	18
14	Conclusiones	19
15	Datos Sintéticos – Generación	20
16	Dataset Sintético – Formato y Variables	21
17	EDA – Boxplots Sintéticos	22
18	Histogramas y Correlaciones	23
19	Metodología	24
20	Limpieza: Atípicos + Imputación Sintética	25
21	Series de Tiempo Sintéticas (ARIMA / SARIMA)	26
22	Resultados – Modelos de Clasificación	27

... **Objetivo General**

Fortalecer y profundizar los conocimientos adquiridos en agricultura predictiva mediante el manejo, limpieza e imputación de datos, así como la implementación y evaluación de modelos predictivos, comprendiendo su importancia y aplicación en la optimización de los procesos agrícolas.



METODOLOGÍA



Data Real

PLANTEAMIENTO DEL PROBLEMA

- Colombia pierde cosechas por deficiencias nutricionales no detectadas a tiempo.
- El análisis foliar mide la concentración de nutrientes en hojas -señal temprana de daño.
- AGROSAVIA registra más de 10.000 muestras foliares de 171 cultivos en 26 departamentos.
Fuente: Datos abiertos agricultura y desarrollo rural
- Sin un modelo predictivo, los técnicos reaccionan tarde, cuando el daño ya es irreversible.



¿Es posible predecir si el rendimiento de un cultivo será BUENO, REGULAR o MALO a partir de sus nutrientes foliares y variables agronómicas?

Desarrollar y comparar modelos de ML supervisados y no supervisados para predecir el rendimiento agrícola foliar colombiano.

DATA REAL

10.027

Registros
Fuente Agricultura y
desarrollo Rural
2018-2024

171
Cultivos

26
Departamentos

23 Variables

1.PROCESAMIENTO

1. Renombrado

23 columnas con nombres extensos → nombres cortos

2. Estandarización

Texto a mayúsculas para unificar categorías

3. Nutrientes símbolos

Valores '<0.03' → imputación con la mitad del límite

4. Top 50 cultivos

171 cultivos → top 50 + categoría OTROS

5. Fertilizante binario

159 valores únicos → 0/1 (no aplicó / sí aplicó)

6. Outliers Fe

Eliminados valores >percentil 99 (>10.000 mg/kg)

DATA REAL

2. Manejo de Atípicos

Distribución de Nutrientes

- Macronutrientes (N, P, K, Ca, Mg, Na, S) en rangos 0–9%.
- Micronutrientes (Fe, Cu, Mn, Zn, B) con rangos amplios en mg/kg.
- Hierro (Fe): valores desde 6 hasta 50.891 mg/kg — alta variabilidad.
- Transformación log1p aplicada para visualización de distribuciones.
- **Robust Scaler** Usa mediana e IQR en lugar de media y desviación estándar,
 - siendo insensible a los outliers extremos de Fe, Mn y Zn
 - Produce rangos comparables entre macronutrientes (%) y micronutrientes (mg/kg), eliminando el sesgo por unidades

DATA REAL




Figura 1. Distribución de datos en box con Outliers.

DATA REAL




Figura 2. Separación categórica de rendimiento por nutriente

DATA REAL




Figura 2. Separación categórica de rendimiento por nutriente

DATA REAL

Serie de Tiempo — Nitrógeno 2018–2024

- Promedio mensual de %_N oscila entre 1% y 4.7%.
 - 2020–2021: mayor estabilidad (~2.2%) por pandemia.
 - Pico en 2022–2023 (~4.7%) seguido de caída abrupta.
 - Serie mensual 2019–2024
- Prueba Dickey-Fuller → serie estacionaria
 - Parámetros definidos con ACF y PACF
 - Modelos evaluados:
 - ARIMA(1,0,1)
 - SARIMAX estacional (m=12)
 - Evaluación con MAE y RMSE



DATA REAL


Serie de Tiempo — Nitrógeno 2018–2024

- Alta variabilidad en la serie
- Influencia del mix de 171 cultivos
- Cambios metodológicos > cambios biológicos
- Promedio nacional poco representativo

- **Recomendación:**

análisis por cultivo



análisis por región



DATA REAL

PCA — Selección y Extracción de Características

- N–S: correlación 0.65 | Ca–B: 0.61 | Ca–Mg: 0.59 → ningún par supera 0.85, todos los 12 nutrientes conservados.
- Se necesitan 11 componentes para explicar el 95% de la varianza — información distribuida en múltiples dimensiones.
- PC1 (29.5%) + PC2 (21.1%) = 50.6% de varianza. Clases BUENO/REGULAR/MALO se solapan → rendimiento depende de múltiples factores.



DATA REAL

PCA — Selección y Extracción de Características

- $PC1 (29.5\%) + PC2 (21.1\%) = 50.6\%$ de varianza. Clases BUENO/REGULAR/MALO se solapan $\rightarrow$ rendimiento depende de múltiples factores.







Modelos Supervisados de Machine Learning

Estrategia ante desbalance: `class_weight='balanced'` — penaliza más errores en clases minoritarias (MALO, REGULAR) sin eliminar datos. Métrica principal: F1-score.

	Modelo	Accuracy	F1-score
0	KNN	0.9370	0.9357
1	Random Forest	0.9311	0.9278
2	Árbol de Decisión	0.8842	0.8845
3	SVM (RBF)	0.8710	0.8771
4	Regresión Logística	0.6408	0.6740

KNN — Detalle por clase de rendimiento

BUENO	Precisión: 0.95 · Recall: 0.97 · F1: 0.96 ✓	REGULAR	Precisión: 0.91 · Recall: 0.86 · F1: 0.89 ✓	MALO	Precisión: 0.79 · Recall: 0.66 · F1: 0.72 ⚠
--------------	---	----------------	---	-------------	---




Optimización, Ensamble e Importancia de Variables

GridSearchCV -5 Folds


- La mayoría de modelos muestran diferencia Train-Test < 0.07 -buena generalización.
- Árbol de Decisión: sobreajuste leve de 0.11 incluso con max_depth optimizado.
- KNN: Train=1.0, Test=0.9465, diferencia 0.0535 — aceptable y esperado.
- Random Forest: sobreajuste mejoró de 0.0722 → 0.0665 con regularización.
- Regresión Logística: modelo más estable (diff=0.0099) pero el menos preciso.

Ensamble

Combina los 5 modelos por votación mayoritaria. Si cada modelo comete errores distintos, el ensamble los compensa → mayor robustez y generalización.



Optimización, Ensamble e Importancia de Variables




Ranking completo:

1. %_Na	0.1356
2. cultivo_agrupado_cod	0.1172
3. departamento_cod	0.1093
4. %_P	0.0838
5. %_N	0.0756
6. %_S	0.0656
7. %_Ca	0.0651
8. mg/kg_B	0.0595
9. %_Mg	0.0545
10. mg/kg_Mn	0.0442
11. mg/kg_Cu	0.0433
12. %_K	0.0393
13. mg/kg_Zn	0.0383
14. mg/kg_Fe	0.0347
15. parte_planta_cod	0.0210
16. fertilizante_bin	0.0130

Métodos No Supervisados - Clustering


K-Means (k=4)

Divide en 4 grupos forzando fronteras esféricas. Los clusters se solapan en espacio PCA — no hay separación clara. Estructura en columnas distribuida entre los 4 grupos.




DBSCAN (eps=2.5)

Detectó 3 clusters basados en densidad + 207 outliers. Los 3 clusters coinciden con las 3 clases de rendimiento. Identifica muestras atípicas automáticamente.



Mean-Shift

Detecta clusters automáticamente sin definir k. Transición gradual de colores — los datos forman un continuo sin grupos claramente separados.



KNN ganó porque en agricultura el contexto lo es todo. Cultivos similares en tipo y región se parecen nutricionalmente. KNN explota esa lógica mejor que cualquier otro modelo.

El talón de Aquiles: la clase MALO. De cada 3 cultivos en mal estado, el modelo falla en 1. No es un problema del algoritmo — es que el mal rendimiento tiene muchas causas y cada una deja una huella distinta. También el data set

Hallazgo inesperado: el sodio lidera. No el nitrógeno, no el fósforo. El sodio, como proxy de estrés salino, resultó ser la señal más predictiva del dataset.

El rendimiento no es una categoría, es un continuo. El clustering lo confirmó: no hay grupos naturales. Clasificar en BUENO, REGULAR y MALO es útil, pero la realidad biológica es más borrosa.

Conclusión. El modelo no predice el futuro — prioriza dónde intervenir. Eso, a escala nacional, ya es suficiente para cambiar cómo Colombia previene pérdidas agrícolas.

DATOS SINTÉTICOS

```
from sklearn.datasets import make_regression
```

- Lotes 70,
- ciclos 2= (abril agosto)-(sept febrero)
- años 8.
- Numero de samples = Lotes * ciclos* años= 1120

Genera 1.120 filas y 15 columnas (variables agronómicas como nitrógeno, pH, NDVI), donde todas las 15 variables contribuyen a predecir el rendimiento del cultivo

(lluvia, plagas, clima) ruido = 0.8.



Dataset y formato

```
scaler_y = MinMaxScaler(feature_range=(4, 12))
#tener valores negativos no tiene sentido en rendimiento agro.
```

Le damos nombres a las variables (15) y RANGOS LÓGICOS)

'temperatura'	: (24, 32), # °C	– rango térmico del Tolima
'precipitacion'	: (100, 400), # mm/mes	– régimen de lluvias
'ndvi'	: (0.35, 0.85), #	– índice de vegetación satelital
'hectareas'	: (25, 50), # ha	– tamaño de cada lote
'num_caballones'	: (40, 120), #	– surcos de drenaje por lote
'ph_agua'	: (6.0, 7.5), #	– calidad del agua de riego

```
1 # leer los primeros 5 registros
2 df.head(5)
```


	año	ciclo	lote	cultivo	departamento	ni
0	2016	1	Lote_01	Arroz	Tolima	
1	2016	1	Lote_02	Arroz	Tolima	
2	2016	1	Lote_03	Arroz	Tolima	
3	2016	1	Lote_04	Arroz	Tolima	
4	2016	1	Lote_05	Arroz	Tolima	

5 rows × 22 columns

EN LA CELDA 6 EN 6 COLUMNAS LE METEMOS 5% DE NULOS



Exploramos la estructura, tipos de dato, **estadísticas básicas** y distribución visual del dataset para entender qué tenemos antes de modelar (.shape, .dtypes, .info(), .describe(), boxplots, histogramas).

Boxplots




- Precipitacion tiene atípicos marcados.
- pH no presenta anomalías.
- ndvi tiene algunos atípicos leves.
- Rendimiento tiene mediana de ~8 t/ha con un atípico bajo en 4.0 t/ha.

Histogramas & Dispersión



Ninguna variable se correlaciona fuertemente con otra — excepto rendimiento ↔ rendimiento_cat (por construcción).



METODOLOGÍA



Limpieza: Atípicos + Imputación

IQR


Precipitación (3 outliers: 650-800 mm) y conductividad eléctrica (2 outliers: 6.5-8.0) límite más cercano

SimpleImputer (media)

Nitrógeno y Fósforo

KNNImputer (k=5 vecinos)

Humedad suelo y NDVI



IterativeImputer (regresión lineal)

Zinc y Silicio
→ micronutrientes relacionados entre sí:

Robust scaler


ME BORRA EL EL DATO DE LA MITAD OSEA DE LA MEDIANA .

NO ME SE HACEN COLAS EN LOS ATIPICOS.

Los atípicos no afectan la mediana ni el IQR — son resistentes a valores extremos.

$\#x_{\text{ESCALADO}} = \frac{x - \text{MEADIANA}}{\text{IQR}}$.

PCA



89.7% info

Series de tiempo:

1

Descomposición

La serie se separó en
tendencia + estacionalidad
+ residuo (error no explicable).

2


Dickey-Fuller

p-value = 1.00 > 0.05
→ serie NO estacionaria.
Se trabajó con la serie original
aceptando la tendencia leve.

3

ACF / PACF

Identificaron los parámetros:
p = 2 (lag PACF)
q = 1 (lag ACF)
→ ARIMA(2,1,1)



Real vs Predicho:

	fecha	real	ARIMA	SARIMA
0	2022-01-31	7.70	8.26	8.35
1	2022-07-31	8.24	8.24	8.61
2	2023-01-31	8.20	8.32	8.62
3	2023-07-31	7.98	8.22	8.82

ARIMA – MAE: 0.234 t/ha

SARIMA – MAE: 0.573 t/ha

→ ↑

→ Gana: ARIMA

Resultados — Modelos de Clasificación


- 80% entrenamiento, 20% prueba.
- X: variables agronómicas escaladas | y: rendimiento_cat (0=bajo, 1=alto)

Modelo	Accuracy	F1-Score	Recall
LASSO	94%	0.94	0.94
Ridge	93%	0.94	0.94
Árbol	67%	0.67	0.67
Random Forest	96%	0.96	0.96
SVM	94%	0.94	0.94
Red Neuronal	94%	0.94	0.94

El árbol fue el peor (67%). Random Forest fue el mejor porque combina 200 árboles y vota por mayoría.

Conclusiones

- Los modelos no lineales (Random Forest, SVM) fueron mejores en este caso , era de esperarse por scikit-learn, que por debajo crea relaciones lineales entre las variables y el rendimiento
- Alternativa para cultivo que no tiene datos bien tomados.
- Tomar mas datos para hacer mejores series de tiempo.



Referencias:

AGROSAVIA. (s.f.). *Datos abiertos*. Corporación Colombiana de Investigación Agropecuaria. <https://www.agrosavia.co/nosotros/transparencia-y-acceso-a-informaci%C3%B3n-p%C3%BAblica/datos-abiertos>

Google LLC. (s.f.). *Google Colaboratory* [Software]. Google. <https://colab.research.google.com>

Padhiary, M., Saha, D., Kumar, R., Sethi, L. N., & Kumar, A. (2024). Enhancing precision agriculture: A comprehensive review of machine learning and AI vision applications in all-terrain vehicles for farm automation. *Smart Agricultural Technology*, 8, 100483. <https://doi.org/10.1016/j.atech.2024.100483>

Python Software Foundation. (2024). *Python* (Versión 3.12) [Software]. <https://www.python.org>